

Reporte de avance — Hackathon 2026

Equipo: Los PoliTiCos **Integrantes:** Juan José Cortés Villamil · Pablo Medina Forero · Miguel Santiago Roa Vallejo **Fecha:** 2 de octubre de 2026

Repositorio: <https://github.com/juan-jose-cortes1234/AIWeekHackaton>

1. Puntaje sobre las preguntas de muestra

Evaluador oficial (`scripts/evaluate.py --ragas`), GPU T4, juez sin fallos, sistema de entrega.

Componente	Puntos	Posibles
Exactitud en cerradas (11 de 15)	14,67	20
Calidad de citación (recall 0,816; 0 citas sin respaldo)	16,33	20
Abstención calibrada (0,837)	8,37	10
Corrección en texto libre — RAGAS (0,4572; referencia 0,451)	13,72	30
Total automático	53,09	80

Evolución: línea base 48,67 → 53,09. Ninguna norma citada carece de respaldo en la evidencia; las normas del fundamento de referencia llegan a la evidencia en 46 de 49 casos. En las 50 preguntas de muestra, RAGAS alcanza 0,4572, por encima del valor de referencia 0,451; los conjuntos evaluados son distintos. Con el umbral de abstención de 0,025 (ver §3) ninguna pregunta de la muestra queda sin fundamento suficiente, por lo que no hubo abstenciones.

2. Estado del corpus

Métrica	Valor
Documentos	650: Constitución, 14 códigos, 149 leyes (16 convenios de doble imposición), 40 decretos, 30 resoluciones, 11 circulares, 2 decisiones andinas, 141 sentencias, 262 conceptos (DIAN, SIC, Supersociedades)
Fragmentos indexados	77.014: 47.340 de artículos, 23.472 de secciones, 1.212 de preámbulos y 4.990 de notas
Áreas del banco cubiertas	Las 10 (de 43 documentos en penal a 252 en tributario)
Cobertura del listado inicial (seed)	98 %–100 % de los ítems por área

3. Arquitectura actual

Componente	Elección
Encoder	BAAI/bge-m3 (MIT)
Decoder	google/gemma-4-E4B-it (Apache-2.0, 7.996.156.490 parámetros), GGUF Q8_0 con su plantilla de chat, temperatura 0
Recuperación	Router de artículos citados + BM25 jurídico + denso (FAISS exacto), fusión RRF, reranker bge-reranker-v2-m3, cupo de 4 normas en los 10 pasajes, evidencia por opción en selección múltiple
Segmentación	Por artículo y por secciones en sentencias y conceptos, con subdivisión de textos extensos e inclusión de preámbulos y notas; cada fragmento lleva el encabezado canónico de su norma
Abstención	En texto libre, <code>abstencion: true</code> cuando el corpus no da fundamento suficiente (ningún pasaje supera 0,025 de pertinencia según el reranker y la pregunta no cita una norma del corpus) o el modelo no produce una respuesta utilizable; en selección múltiple siempre se elige una opción

4. Riesgos identificados

- Exactitud en cerradas (73 %):** el modelo de 8B elige distinto según cómo se le presentan las opciones, aun con la norma en la evidencia; seguimos trabajando la selección de evidencia.
- Tiempo de cómputo:** ~40 s por pregunta en una T4 (992 ≈ 11 h de cómputo). Plan: 6 equipos en paralelo —3 de la sala Turing y 3 portátiles con Colab—, un rango de ~165 preguntas cada uno (`run.py --rango INICIO FIN`), ≈ 2 h. Riesgos: la ejecución por consola aún no se ha ensayado en Turing (ensayo previsto antes del sábado) y Colab puede negar GPU por cuota (respaldo: Kaggle).
- Posibles inconsistencias en las claves de la muestra, pendientes de verificación:** en la pregunta 58 la opción correcta dice «Ley 1564 de 2002», mientras que el Código General del Proceso es la Ley 1564 de 2012; en la 128 la clave incluye a las Fintech, que el Decreto 2555 de 2010 no menciona entre quienes pueden celebrar leasing financiero.