

Reporte de avance — Hackathon 2026

Equipo: Los PoliTiCos **Integrantes:** Juan José Cortés Villamil · Pablo Medina Forero · Miguel Santiago Roa Vallejo **Fecha:** 2 de octubre de 2026

1. Puntaje sobre las preguntas de muestra

Evaluador oficial (`scripts/evaluate.py --ragas`), GPU T4, juez sin fallos (corrida `muestra_v12`).

Componente	Puntos	Posibles
Exactitud en cerradas (11 de 15)	14,67	20
Calidad de citación (recall 0,816; 0 citas sin respaldo)	16,33	20
Abstención calibrada (0,837)	8,37	10
Corrección en texto libre — RAGAS (0,4572; referencia 0,451)	13,72	30
Total automático	53,09	80

Evolución: línea base 48,67 → 53,09. Ninguna norma citada carece de respaldo en la evidencia; las normas del fundamento de referencia llegan a la evidencia en 46 de 49 casos. En texto libre la corrección supera la referencia del estudio (0,451).

2. Estado del corpus

Métrica	Valor
Documentos	650: Constitución, 14 códigos, 149 leyes (16 convenios de doble imposición), 40 decretos, 30 resoluciones, 11 circulares, 2 decisiones andinas, 141 sentencias, 262 conceptos (DIAN, SIC, Supersociedades)
Fragmentos indexados	77.014 (por artículo; sentencias por secciones)
Áreas del banco cubiertas	Las 10 (de 43 documentos en penal a 252 en tributario)
Cobertura del listado inicial (seed)	98 %–100 % de los ítems por área

3. Arquitectura actual

Componente	Elección
Encoder	BAAI/bge-m3 (MIT)
Decoder	google/gemma-4-E4B-it (Apache-2.0, 7.996.156.490 parámetros), GGUF Q8_0 con su plantilla de chat, temperatura 0
Recuperación	Router de artículos citados + BM25 jurídico + denso (FAISS exacto), fusión RRF, reranker bge-reranker-v2-m3, cupo de 4 normas en los 10 pasajes, evidencia por opción en selección múltiple
Segmentación	Por artículo con encabezado canónico de la norma; sentencias por secciones
Abstención	Solo si el modelo no produce una respuesta utilizable (con los pesos oficiales, responder suma más)

4. Riesgos identificados

- Exactitud en cerradas (73 %):** el modelo de 8B elige distinto según cómo se le presentan las opciones, aun con la norma en la evidencia; seguimos trabajando la selección de evidencia.
- Tiempo de cómputo:** ~40 s por pregunta en una T4 (992 ≈ 11 h); el banco se repartirá por rangos entre varias GPU de la sala Turing (`run.py --rango`).
- Claves discutibles en la muestra:** 2 de las 4 preguntas de selección múltiple falladas tienen una clave con errata o más amplia que la norma.