

Informe técnico — Los PoliTicos

Hackathon 2026 · Universidad de los Andes Integrantes: Juan José Cortés Villamil · Pablo Medina Forero · Miguel Santiago Roa Vallejo

1. Arquitectura del sistema

Una pregunta recorre cinco etapas deterministas, ejecutadas en proceso con modelos abiertos descargados de Hugging Face. Ningún modelo cerrado ni API de terceros interviene; una lista blanca de modelos abiertos en la configuración lo impone. El único servicio externo es el juez de RAGAS, que usa el evaluador oficial.

- Ingesta.** 650 documentos oficiales (Constitución, códigos, leyes —incluidos 16 convenios para evitar la doble imposición—, decretos, resoluciones, circulares, sentencias y conceptos de DIAN, SIC y Supersociedades) se limpian y se segmentan **por artículo y por secciones** en sentencias y conceptos (en sentencias, detectadas de forma estricta: antecedentes, consideraciones, resuelve, salvamentos), con subdivisión de textos extensos e inclusión de preámbulos y notas de vigencia. Cada fragmento empieza con el nombre canónico de su norma («Ley 1150 de 2007, artículo 11.»), verificado con el extractor de citas del evaluador. Una guardia anti-fuga bloquea la indexación si detecta material del banco de preguntas.
- Indexación.** 77.014 fragmentos (47.340 de artículos, 23.472 de secciones, 1.212 de preámbulos y 4.990 de notas): vectores `bge-m3` en FAISS exacto y BM25 con un tokenizador jurídico que conserva números de artículo y de sentencia. El índice se congela por sha256.
- Recuperación.** Router de artículos citados en la pregunta + BM25 + denso, fusionados con RRF, sesgo por área, topes de diversidad (por artículo y 4 por documento), reordenamiento con `bge-reranker-v2-m3` y un **cupó de 4 normas** entre los 10 pasajes para que los fragmentos de sentencia no desplacen a los artículos. En selección múltiple, 4 puestos son para la pregunta y el resto se reparte entre las opciones, cada una buscada con su texto más las palabras más raras de la pregunta.
- Generación.** El decoder recibe los 10 pasajes numerados [P1]...[P10] completos, con la plantilla de chat propia del modelo, y produce el JSON del formato, forzado con una gramática derivada del esquema. En selección múltiple, el prompt pide elegir la opción que mejor coincide con la evidencia, tolerando errores de digitación en números y años, y maneja opciones combinadas («(a) y (b)», «Todas las anteriores»).
- Verificación.** Un post-filtro elimina toda cita que no figure en los 10 pasajes y las referencias se renderizan desde los encabezados de los pasajes. La línea se valida contra el esquema oficial.

2. Selección de encoder y decoder

Componente	Modelo	Motivo	Alternativas
Encoder	BAAI/bge-m3 (MIT)	Multilingüe, fuerte en español, 1.024 dimensiones (fragmentos de hasta 512 tokens)	multilingual-e5-large (en lista blanca); jina-embeddings-v3 descartado por licencia CC-BY-NC
Decoder	google/gemma-4-E4B-it (Apache-2.0), GGUF Q8_0, con su plantilla de chat y sin canal de razonamiento	7.996.156.490 parámetros en total (bajo el límite de 8B); con su plantilla propia superó a Qwen3-8B en la muestra	Qwen/Qwen3-8B (Apache-2.0, GGUF Q4_K_M): versión anterior del sistema
Reranker	BAAI/bge-reranker-v2-m3 (Apache-2.0)	Cross-encoder multilingüe, coherente con el encoder	Sin reranker

Inferencia. Temperatura 0 (decodificación voraz), semilla fija, sin modo de razonamiento, ventana de 8.192 tokens, `llama.cpp` en GPU. Tiempo por pregunta en una T4: 40 s en promedio (selección múltiple 40 s, semiabiertas 34 s, abiertas 76 s). Para las 992 preguntas (~11 h en una GPU) el banco se reparte por rangos entre varias máquinas (`run.py --rango INICIO FIN`). La corrida es reproducible: dos ejecuciones en máquinas distintas produjeron respuestas idénticas.

3. Estrategia de recuperación

- **Segmentación:** un fragmento por artículo (con párrafos); artículos de más de 300 palabras se parten repitiendo el encabezado; sentencias y conceptos por secciones, en ventanas de ~300 palabras con 15 % de solape; preámbulos y notas de vigencia como fragmentos propios ligados a su norma.
- **Fusión:** RRF ($k = 60$) de 50 candidatos densos y 50 léxicos; el reranker ordena los 20 mejores.
- **Selección múltiple:** evidencia representativa por opción, marcada en el prompt («recuperado para la opción B»).
- **Medida guía:** las normas del fundamento de referencia aparecen en la evidencia en 46 de 49 casos (94

%), y en 40 de las 41 preguntas con fundamento citable hay al menos una.

4. Verificación de citas y abstención

Citas. El evaluador compara normas a nivel de cuerpo y castiga con el doble toda cita ausente de los 10 pasajes. Por eso: (i) cada pasaje empieza con el nombre canónico de su norma; (ii) el post-filtro localiza cada cita con las mismas expresiones regulares del evaluador y reemplaza las no respaldadas por «la normativa aplicable»; (iii) las leyes citadas sin año se completan cuando los pasajes lo resuelven; (iv) el «Fundamento normativo» se construye desde los encabezados de los pasajes. Resultado: **0 citas sin respaldo** en todas las corridas.

Abstención. El sistema registra `abstencion: true` en texto libre cuando el corpus no da fundamento suficiente —ningún pasaje supera 0,025 de pertinencia según el reranker y la pregunta no cita una norma presente en el corpus— o cuando el modelo no produce una respuesta utilizable. El umbral es bajo a propósito: con los pesos oficiales, una respuesta fundamentada vale más que la abstención. En selección múltiple siempre se elige una opción, porque responder aporta más que abstenerse incluso al azar. Las respuestas respetan los límites del enunciado: semiabiertas de 3 a 5 oraciones y máximo 150 palabras; análisis de las abiertas de 5 a 8 oraciones, con un tope total de 500 palabras.

5. Resultados sobre las preguntas de muestra

Evaluador oficial (`scripts/evaluate.py --ragas`), sistema de entrega (umbral de abstención 0,025), juez sin fallos. Ninguna pregunta de la muestra queda por debajo del umbral (pertinencia mínima 0,034), por lo que no hubo abstenciones:

Componente	Puntos	Posibles
Exactitud en cerradas (11 de 15)	14,67	20
Calidad de citación (recall 0,816; 0 sin respaldo)	16,33	20
Abstención calibrada (0,837)	8,37	10
Total automático sin RAGAS	39,37	50
Corrección en texto libre — RAGAS (0,4572; referencia 0,451)	13,72	30
Total automático	53,09	80

Evolución. Línea base 48,67 (Qwen3-8B, 186 documentos) → 49,64 (238 documentos) → **53,09** (Gemma 4 E4B, 650 documentos). Cambios que aportaron: evidencia por opción en selección múltiple, cupo de normas (+3 citas acertadas), no abstenerse (+2 preguntas respondidas), las reglas de elección del prompt de selección múltiple (+1) y la plantilla de chat propia de Gemma 4 junto con la ampliación del corpus (+1 en selección múltiple, +2 citas, RAGAS 0,428 → 0,457). Cambios que no aportaron y se retiraron: el razonamiento de Qwen3 en selección múltiple (+1 acierto en una corrida y 0 en la siguiente, con el doble de tiempo y menos citas) y la respuesta en abierto antes de elegir (+1 acierto con el doble de latencia). Lección metodológica: varias caídas aparentes de RAGAS eran respuestas sin veredicto del juez por fallos de red, que el evaluador cuenta como cero.

Errores en selección múltiple (4 de 15). 647 (la ayuda como efecto personal del matrimonio: la evidencia son sentencias y no el art. 176 del Código Civil), 671 (reglas de desempate de residencia en convenios de doble imposición: doctrina) y dos claves discutibles: - 58, que pide la «Ley 1564 de 2002» (el Código General del Proceso es de 2012), y 128, que exige «Fintech» cuando la norma solo nombra bancos y compañías de financiamiento.

6. Limitaciones

1. **Dependencia del corpus:** una norma ausente no se puede citar con respaldo; el filtro evita inventarla, pero la respuesta pierde fundamento.
2. **Citas a nivel de cuerpo:** la verificación garantiza que la norma citada está en la evidencia, no que el artículo concreto sea el pertinente.
3. **Razonamiento del modelo de 8B:** en selección múltiple, con la misma evidencia la letra elegida varía según cómo se presentan las opciones. La exactitud (0,73) sigue lejos de la referencia (0,905).
4. **Costo de cómputo:** ~40 s por pregunta en GPU T4 y ~3,5 min en CPU; el banco completo requiere varias GPU en paralelo.
5. **Doctrina no normativa:** las preguntas cuyo fundamento es doctrina o derecho extranjero (p. ej. el caso *Dow Chemical*) solo se responden con evidencia parcial.